

# Проблема несбалансированности

Виктор Панкратов

6 марта 2021 г.

## 1 Постановка задачи

### 1.1 Общая постановка

Пусть  $D$  - множество документов,  $T$  - конечное множество тем. Каждый из документов  $d \in D$  задается его длиной  $n_d$  и последовательностью термов  $\{w_i \in W\}_{i=1}^{n_d}$ , элементы которой в дальнейшем будем называть словами. Вероятностная модель порождения коллекции вводится при следующих дополнительных предположениях

- Гипотеза мешка слов: вышеописанное представление документа эквивалентно представлению документа в виде неупорядоченного множества входящих в него слов, в которое каждое слово  $w$  входит  $n_{wd}$  раз.
- Гипотеза о существовании тем: каждое вхождение слова в документ связано с некоторой темой  $t \in T$
- Гипотеза условной независимости: вероятность появления слова  $w$  в документе  $d$  по теме  $t$  не зависит от документа  $d$  и описывается распределением

$$p(w|d, t) = p(w|t)$$

При таких условиях вероятность появления слова  $w$  в документе  $d$  описывается распределениями  $p(w|t) = \phi_{wt}$ ,  $p(t|d) = \theta_{td}$ . Задача тематического моделирования заключается в нахождении этих распределений. Это эквивалентно задаче получения матричного разложения

$$F = \Phi\Theta \quad (1)$$

$$F = \left( \frac{n_{wd}}{n_d} \right)_{W \times D} \quad \Phi = (\phi_{wt})_{W \times T} \quad \Theta = (\theta_{td})_{T \times D}$$

Данную задачу решают максимизацией с помощью *ЕМ*-алгоритма функции правдоподобия

$$\sum_{d \in D} \sum_{w \in d} n_{dw} \ln \sum_{t \in T} \phi_{wt} \theta_{td} \rightarrow \max_{\Phi, \Theta} \quad (2)$$

Задача (1) поставлена некорректно: в общем случае ее множество решений бесконечно. Чтобы уменьшить множество решений, в функцию (2) добавляют один или несколько регуляризаторов, зависящих от матриц  $\Phi, \Theta$ . Функция правдоподобия при этом принимает следующий вид:

$$\sum_{d \in D} \sum_{w \in d} n_{dw} \ln \sum_{t \in T} \phi_{wt} \theta_{td} + \sum_i \tau_i R_i(\Phi, \Theta) \rightarrow \max_{\Phi, \Theta} \quad (3)$$

## 1.2 Проблема несбалансированности

Вышеописанная модель склонна выделять равномошные темы, то есть при  $n_t$  определенном как  $n_t = \sum_{d \in D} p(t|d)n_d \Rightarrow \forall t_i, t_j \in T \rightarrow \frac{n_{t_1}}{n_{t_2}} \approx 1$ , что получило название "проблема несбалансированности". Такой эффект возникает из-за изначальной постановки задачи: при максимизации правдоподобия модели выгодно использовать все свои параметры. В свою очередь, сокращение долей отдельных тем приводит к неполному использованию, а в пределе - к уменьшению числа параметров. В реальных же коллекциях темы могут оказаться несбалансированными. Чтобы модель и в таком случае корректно выделила темы, в нее предлагается добавить регуляризатор  $R$ :

$$R = \sum_{d \in D} \sum_{w \in d} \beta_{dw} n_{dw} \ln \sum_{t \in T} \phi_{wt} \theta_{td} \quad (4)$$

$$\beta_{dw} = \sum_{t \in T} \frac{p(t|d, w)}{p_t} \quad p_t = \frac{n_t}{n}$$

Введение данного регуляризатора эквивалентно требованию минимизации суммарной семантической неоднородности тем.

$$\sum_{t \in T} S_t = \sum_{d \in D} \sum_{w \in d} \left( \sum_{t \in T} \frac{n_{tdw}}{n_t} \right) \ln \frac{\hat{p}(w|d)}{p(w|d)} \rightarrow \min_{\Phi, \Theta} \quad (5)$$

В данной работе будет исследована зависимость качества получаемого решения задачи(1) от добавления регуляризатора  $R$ , показано, как введение этого регуляризатора изменяет статистику  $S_t$  а также проанализировано влияние  $R$  в совокупности с другими регуляризаторами, представленными в работах ранее.

### 1.2.1 Регуляризатор декоррелирования

$$R_1 = - \sum_{t \in T} \sum_{s \in T \setminus t} \sum_{w \in W} \phi_{wt} \phi_{ws} \quad (6)$$

Введение данного регуляризатора эквивалентно требованию находить различные темы, т е уменьшению ковариации тем.

### 1.2.2 Регуляризатор сглаживания

$$R_2 = - \sum_{t \in T} \sum_{w \in W} \alpha_{wt} \ln \phi_{wt} \quad (7)$$

Введение данного регуляризатора эквивалентно близости  $\phi_t$  к заданному распределению  $\alpha_t$ . Аналогично вводится сглаживание для матрицы  $\Theta$

## 2 Эксперимент

### 2.1 Генерация коллекции

Для эксперимента будем генерировать синтетическую коллекцию данных. Процесс генерации условно можно разделить на 2 этапа: генерация матриц  $\Phi, \Theta$  и построение документов по ним.

### 2.1.1 Генерация матриц

Столбцы матриц  $\Phi, \Theta$  порождаются симметричными распределениями Дирихле. Параметр распределения определяется из соображений реалистичности коллекции и берется малым для разреженности получаемых матриц. Для матрицы  $\Phi$  он берется равным  $\approx 0.01$ , для матрицы  $\Theta \approx 0.1$ . Чтобы регулировать баланс тем будем на этом этапе менять наибольшие значения в столбцах  $\Theta$  с необходимыми для эксперимента.

### 2.1.2 Генерация документов

Для генерации очередного слова  $w_i$  сначала генерируется тема  $t_i$  документа из соответствующего этому документу столбцу матрицы  $\Theta$ . Затем слово генерируется из столбца  $\Phi$ , соответствующего теме  $t_i$ . Таким образом, процесс генерации документов описывается как

$$t_i \sim Dir(t|d) \quad w_i \sim Dir(w|t_i) \quad i \in 1 \dots n_d$$

## 2.2 Стандартная модель

Сгенерируем вышеописанным образом несколько коллекций с различной степенью несбалансированности. Для каждой из них используем стандартную модель для нахождения матриц  $\Phi, \Theta$ . Чтобы оценить сходство полученных матриц  $\Phi_{exp}$  с используемыми при генерации в данной работе считается количество взаимно ближайших по евклидовой метрике столбцов матриц  $\Phi, \Phi_{exp}$ , то есть пар столбцов  $\Phi[i], \Phi_{exp}[j]$ :

$$\arg \min_k (dist(\Phi[i], \Phi_{exp}[k])) = j$$


$$\arg \min_k (dist(\Phi[k], \Phi_{exp}[j])) = i$$

$dist$  в формулах выше - евклидово расстояние. Оно выбрано исключительно для демонстрации в данном отчете.

На графике 1 представлены результаты описанного эксперимента. Видно, что при увеличении степени несбалансированности качество решения падает.

## 2.3 Добавление регуляризатора

Теперь рассмотрим, как введение регуляризатора  $R$  улучшает качество модели. Добавим регуляризатор  $R$  в модель и повторим предыдущий эксперимент. Результаты представлены на графике 2.



В данном эксперименте использовался постоянный коэффициент регуляризации  $\tau = 0.5$ . Видно, что качество решения продолжает ухудшаться при увеличении степени несбалансированности, однако гораздо медленнее, чем в первом случае.